

Ejercicio Práctico en Orange: Clasificación de Clientes (Regresión Logística)

Objetivo: Desarrollar y evaluar un flujo de trabajo de *machine learning* completo en Orange para predecir un resultado binario utilizando un mínimo de tres modelos, con especial énfasis en la Regresión Logística y las métricas de evaluación clave.

Dataset: Utilizarán el dataset de **Bank Marketing** (accesible en Orange vía el widget **Dataset**), cuyo objetivo es predecir si un cliente se suscribirá a un depósito a plazo fijo (y o n).

Instrucciones

1. Carga y Exploración (EDA)

- Carguen el dataset en Orange.
- Identifiquen y asignen correctamente los roles de las variables (**Característica**, **Clase**, **Meta** e **Ignorar**).
- Utilicen los *widgets* **Data Table**, **Distributions** y **Feature Statistics** para realizar un Análisis Exploratorio de Datos (EDA). Describan en un párrafo la distribución de la variable objetivo y al menos dos variables predictoras importantes (ej. **age** y **poutcome**).

2. Preprocesamiento de Datos

- Utilicen el *widget* **Select Columns** para gestionar el tipo de variables.
- Implementen el *widget* **Continuize** (o métodos de codificación) para manejar las variables categóricas nominales y ordinales, preparándolas para el modelado.
- Si el dataset presenta datos faltantes, usen el *widget* **Impute** para completar dichos valores.

3. División de Datos

- **División (Split):** utilizar el widget de split para dividir los datos en 80% para training y 20% para testing

4. Modelado y Entrenamiento (Mínimo 3 Modelos)

- Conecten el dataset preprocesado al *widget* **Test and Score**.
- Incluyan y entrenen los siguientes modelos en el **Test and Score**:
 - **Logistic Regression**
 - **Random Forest**
 - **Naive Bayes** (o Support Vector Machine)

5. Evaluación y Visualización de Resultados

- **Matriz de Confusión:** Conecten el **Test and Score** al *widget* **Confusion Matrix**. Generen la matriz para el modelo de **Regresión Logística**.
- **Curva ROC:** Conecten el **Test and Score** al *widget* **ROC Analysis**. Visualicen y comparen las curvas de los tres modelos.

Entregables y Preguntas de Análisis

1. **Workflow de Orange:** Un archivo de Orange (**.ows**) con el flujo completo.

2. Reporte (Respuestas):

- Muestren la tabla de métricas del **Test and Score**. ¿Qué modelo logró el mejor **AUC** y cuál el mejor **F1-score**?

En la tabla de métricas del Test and Score, se evaluaron tres modelos: Logistic Regression, Random Forest y Naive Bayes. El modelo que logró el mejor AUC fue la Regresión Logística, con un valor de 0.927, lo que indica que es el modelo con mayor capacidad para distinguir entre clases. Asimismo, el mejor F1-score también correspondió a la Regresión Logística, con un valor de 0.905, reflejando el mejor equilibrio entre precisión y recall. En conclusión, la Regresión Logística fue el modelo de mejor desempeño general en esta evaluación.

Test and Score

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.927	0.914	0.905	0.904	0.914	0.497
Random Forest	0.889	0.897	0.885	0.881	0.897	0.383
Naive Bayes	0.830	0.840	0.857	0.885	0.840	0.398

Compare models by: Area under ROC curve Negligible diff.: 0.1


	Logistic Regression	Random Forest	Naive Bayes
Logistic Regression		0.988	0.997
Random Forest	0.012		0.977
Naive Bayes	0.003	0.023	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

- A partir de la Matriz de Confusión de la Regresión Logística, identifiquen y reporten los valores de **TP, TN, FP y FN**.

A partir de la Matriz de Confusión de la Regresión Logística, se identificaron los siguientes valores: los Verdaderos Positivos (TP) fueron 159, correspondiendo a los casos en que el modelo predijo “yes” y el valor real también era “yes”. Los Verdaderos Negativos (TN) fueron 2853, donde el modelo predijo “no” y el valor real

era efectivamente “no”. Los Falsos Positivos (FP) fueron 77, es decir, casos en que el modelo predijo “yes” cuando en realidad eran “no”. Finalmente, los Falsos Negativos (FN) fueron 207, representando los casos en que el modelo predijo “no” pero el valor real era “yes”.



- Analicen la curva ROC: ¿Cuál de los tres modelos exhibe el mejor *trade-off* entre Tasa de Verdaderos Positivos (TPR) y Tasa de Falsos Positivos (FPR)?

El modelo con mejor trade-off es la Regresión Logística (línea verde), ya que su curva se ubica más cerca del vértice superior izquierdo del gráfico, lo que significa que logra una alta Tasa de Verdaderos Positivos (TPR) con una baja Tasa de Falsos Positivos (FPR). Esto es consistente con su AUC de 0.927 visto anteriormente. Random Forest queda en segundo lugar, y Naive Bayes presenta la curva más alejada del vértice ideal.

