



Trabajo Práctico Final

Big Data 2026

Data Set: Fuga de Talentos

Integrantes: Francisco Cavanagh, Ignacio Mendonca,
Clara Pochat, Malena Urso y Lucas Rudolph

Contexto del negocio

GrupoSer S.A. es un conglomerado argentino de servicios con alcance en CABA, GBA y las provincias centrales. Posee una nómina de **10.000 empleados** en sectores como Comercial, IT, Operaciones, Finanzas, Marketing, RRHH y Legal.

Durante el último bienio, la rotación de personal emergió como el desafío crítico para Recursos Humanos. El impacto financiero es significativo: cada baja voluntaria le cuesta a la compañía entre **6 y 9 meses de salario**, considerando reclutamiento, capacitación y desajuste operativo.

A través de este dataset, People Analytics busca adelantarse a la tendencia: detectar con un horizonte de 12 meses qué perfiles presentan mayor riesgo de salida.

La información, consolidada desde sistemas HRIS, encuestas de clima y payroll, requiere ahora un **modelo de clasificación**. El objetivo es que RRHH pueda priorizar acciones preventivas —diálogos, beneficios o planes de carrera— antes de que la renuncia sea irreversible.

Selección del data set

Al abrir el archivo en Orange, el widget Data Table muestra 10.000 filas y 15 columnas. La variable target es **renuncio_12m** con valores 0 (no renunció) y 1 (renunció). El widget **Distributions** muestra que el **46.01%** (4601) tiene valor 0 y el **53.99%** (5399) tiene valor 1 → hay un desbalance moderado.

El tipo de problema queda definido: **clasificación binaria**. Queremos predecir una de dos clases posibles.

Definición del problema

Problema: predecir qué empleados tienen mayor riesgo de renunciar en los próximos 12 meses, para priorizar acciones de retención antes de que sea tarde.

¿Quién usa el modelo? El área de People Analytics lo usa mensualmente para generar un ranking de riesgo y pasárselo a los managers de cada área.

¿Cuál es el error más costoso?


Falso negativo: predecir "no renuncia" cuando sí renuncia → perdemos la oportunidad de retenerlo. Costo estimado: 6–9 meses de salario.

Falso positivo: predecir "renuncia" cuando no renuncia → hacemos acciones de retención innecesarias. Costo: menor.

Conclusión: queremos maximizar Recall, aunque sacrifiquemos algo de Precisión.

Pipeline en Orange

Se realizó el análisis del dataset mediante Orange Data Mining, aplicando técnicas de exploración, preparación de datos y modelado predictivo para identificar los principales factores asociados a la renuncia de empleados y evaluar la capacidad de distintos algoritmos para predecir este comportamiento.



Análisis Exploratorio de Datos

Hipótesis:

H1 — Salario relativo a la región ¿Los empleados cuyo salario está por debajo de la mediana salarial de su provincia presentan una mayor tasa de renuncia que aquellos que están por encima de esa mediana

H2 — Flexibilidad y distancia ¿Los empleados en modalidad presencial que viven a más de 30 km de la oficina tienen una tasa de renuncia significativamente mayor que quienes trabajan en modalidad híbrida o remota con la misma distancia?


H3 — Burnout por sobretiempo y clima bajo ¿Los empleados que combinan más de 20 horas extra mensuales con un score de clima laboral menor a 4 presentan una tasa de renuncia superior a la de quienes tienen solo uno de esos dos factores?


H4 — Estancamiento profesional ¿Los empleados con una proporción alta entre años en el rol actual y años totales en la empresa (ratio cercano a 1, con más de 4 años en la firma) muestran una tasa de renuncia superior a quienes han tenido movilidad interna?

H5 — Presión por desempeño en los extremos ¿Los empleados con evaluaciones de desempeño en los extremos (puntaje 1 o puntaje 5) presentan tasas de renuncia más altas que quienes tienen evaluaciones intermedias, aunque por razones opuestas?

Hallazgos:


H1 — Salario relativo a la región






La hipótesis no se confirma. Si bien en el extremo izquierdo de la distribución (salarios más bajos) la relación entre permanencia y salida se mantiene equilibrada, la brecha a favor de las renuncias se ensancha notablemente hacia el centro y el extremo derecho de la campana. Esto demuestra que a mayor nivel salarial, mayor es la tasa de renuncia, concentrándose el riesgo en los ingresos medios y altos. Por último, al analizar por provincia, se observa que el comportamiento de la fuga de talentos es homogéneo en todas las provincias.

H2 — Flexibilidad y distancia




La hipótesis no se confirma. La diferencia entre modalidades es de apenas 1.4 puntos porcentuales (54.5% remoto vs 53.1% presencial), y la correlación de distancia_oficina_km con renuncia es $r = 0.005$. Ni la modalidad ni la distancia operan como predictores relevantes en este dataset.

H3 — Burnout por sobretiempo y clima bajo




Esta es la hipótesis con mayor respaldo. El subgrupo con clima ≤ 3 y horas extra > 20 alcanza una tasa de renuncia del 77.1%, frente al 54% global. La combinación de ambos factores supera a cualquiera de los dos por separado (clima bajo solo: 67.2%; horas altas solas: ~59%), lo que indica un efecto de interacción real entre estrés ambiental y carga laboral. El boxplot complementa el análisis, quienes permanecen en la encuesta de clima tienen una media de 6.42. Y quienes renuncian tienen una media en la encuesta de 4.74, marcando insatisfacción laboral.

H4 — Estancamiento profesional



Se confirma parcialmente. Empleados con 4 o más años en el mismo rol tienen una tasa de renuncia del 61–62%, contra 48% en quienes llevan menos de 3 años en el rol. Sin embargo, la correlación de años en empresa es menor ($r = 0.09$) que la de años en rol ($r = 0.12$), lo que sugiere que el factor clave es la falta de movilidad dentro de la empresa, no la antigüedad total.

H5 — Presión por desempeño en los extremos



No se confirma. La correlación entre evaluación y renuncia es $r = -0.014$, prácticamente cero, y la distribución de renunciantes es uniforme a lo largo de todos los valores de evaluación. Ni los mal evaluados ni los sobresalientes muestran tasas de salida diferenciales, lo que descarta tanto la hipótesis de despido inminente como la de fuga por mejores ofertas externas.

Preprocesamiento

La etapa de preprocesamiento tuvo como objetivo garantizar la calidad, consistencia y relevancia de la información utilizada para el análisis predictivo de la rotación de empleados.

Calidad de los datos


En primer lugar, se realizó una revisión integral de la base de datos para identificar posibles problemas de calidad. El análisis confirmó que no existían valores nulos en las variables consideradas para el estudio, por lo que no fue necesario aplicar técnicas de imputación o reemplazo de datos faltantes.

Asimismo, se verificó la consistencia de las variables categóricas y numéricas. Los registros que presentaban distintas codificaciones para una misma categoría fueron normalizados antes de la carga definitiva de los datos, garantizando la uniformidad de la información utilizada durante el proceso de modelado.

Column Statistics									Mon Jun 08 26, 17:47:37	
Column	Distribution	Mean	Mode	Median	Dispersion	Min.	Max.	Missing		
N id_empleado		5000.50	1	5000.50	0.58	1	10000	0 (0 %)		
N anios_empresa		6.98	6	7	0.62	0	14	0 (0 %)		
N anios_rol_actual		3.48	0	3	0.97	0	14	0 (0 %)		
N evaluacion_desempeno		2.99	4	3	0.47	1	5	0 (0 %)		
N horas_extra_mes		19.59	4	20	0.59	0	39	0 (0 %)		
N dias_vacaciones_restantes		9.89	0	10	0.61	0	20	0 (0 %)		
N distancia_oficina_km		25.58	24	26	0.54	2	49	0 (0 %)		
N encuesta_clima_score		5.52	8	6	0.52	1	10	0 (0 %)		
N edad		41.83	34	41	0.47	-5	200	0 (0 %)		
N salario_ars		801582	298085	799488	0.247837	63126	1.51012e+06	0 (0 %)		
C genero			Masculino		0.85			0 (0 %)		
C provincia			Neuquen		2.08			0 (0 %)		
C estado_civil			Soltero		1.1			0 (0 %)		
C nivel_educativo			Universitario		0.892			0 (0 %)		
C modalidad_trabajo			Hibrido		1.1			0 (0 %)		
C renuncia_12m			1		0.69			0 (0 %)		


Tratamiento de valores atípicos

Se realizó un análisis de las estadísticas, para detectar valores atípicos. Como resultado, se identificaron registros con edades imposibles o inconsistentes para la población laboral analizada. Estos casos representaban aproximadamente el 2% de las observaciones totales y fueron eliminados del conjunto de datos, ya que podían distorsionar los resultados y afectar el desempeño de los modelos predictivos.




Variables derivadas

Con el objetivo de incorporar indicadores con mayor capacidad explicativa sobre la probabilidad de renuncia, se construyeron nuevas variables derivadas:




Índice de estancamiento: calcula la proporción del tiempo total trabajado en la empresa que ha transcurrido en el puesto actual. Valores elevados pueden reflejar una menor movilidad interna o menores oportunidades de crecimiento profesional, factores frecuentemente asociados con la intención de abandono.



Alerta Burnout: variable compuesta que combina la cantidad de horas extras realizadas y la percepción del clima laboral. El objetivo es identificar empleados con potencial riesgo de desgaste laboral, considerando simultáneamente la carga de trabajo y el nivel de satisfacción dentro de la organización. Se puede observar lo siguiente:

Los que se quedan (0): Tienen un nivel de burnout promedio de **4.11**.

Los que se renuncian (1): Tienen un nivel de burnout promedio de **7.13** (casi el doble).



Selección de variables

Durante la preparación de los datos se eliminaron variables sin valor predictivo para el problema de negocio.

ID Empleado: fue excluida del análisis por tratarse de un identificador único cuya función es únicamente administrativa. Al no contener información relacionada con el comportamiento o las características de los empleados, su inclusión podría introducir ruido en el modelo sin aportar capacidad predictiva.

Features (14)

Filter

C

provincia

C

estado_civil

C

modalidad_trabajo

N

anios_empresa

N

anios_rol_actual

N

evaluacion_desempeno

N

horas_extra_mes

N

dias_vacaciones_restantes

Target (1)

C

renuncia_12m

Metas (1)

N

id_empleado


Modelado

Para garantizar la capacidad de generalización de los modelos, el conjunto de datos procesados se introdujo en un módulo de muestreo (*Data Sampler*). Utilizando este nodo, los datos fueron divididos aleatoriamente en dos subconjuntos independientes bajo una proporción de 80/20:

- **Conjunto de Entrenamiento (*Training* - 80%)**: Destinado exclusivamente al ajuste, aprendizaje y calibración de los algoritmos de clasificación.
- **Conjunto de Prueba (*Test* - 20%)**: Reservado de manera aislada con el fin de realizar la validación final y evaluar el rendimiento real de los modelos ante datos no vistos durante el entrenamiento.

Se diseñó una estrategia de modelado predictivo basada en el aprendizaje supervisado para clasificación binaria. Se implementaron y evaluaron tres algoritmos mediante validación cruzada.

Modelo	Hiperparámetros
Logistic Regression	Tipo de regularización: Ridge (L2) (para evitar el sobreajuste penalizando los coeficientes grandes). Fuerza de regularización (C): C=1 (fuerza de regularización moderada/estándar).
Random Forest	Número de árboles: 100 . Control de crecimiento: No se limitó la profundidad máxima de los árboles individuales, pero se estableció que no se dividan subconjuntos menores a 5 muestras para controlar el sobreajuste.
Naive Bayes	Default



Para garantizar una evaluación justa, transparente y mitigar el sesgo de selección en los datos, se implementó el widget **Test and Score** configurado con **Validación Cruzada Estratificada de 10 pliegues (Stratified Cross-Validation, k=10)**.

Este método divide el dataset en 10 partes iguales, asegurando que la proporción de la variable objetivo (empleados que renuncian vs. empleados que se quedan) se mantenga idéntica en cada pliegue. El proceso se repite 10 veces, rotando el pliegue de prueba en cada iteración, y los resultados finales corresponden al promedio de estas métricas.

Test and Score

Cross validation

- Number of folds: 10
- ☒ Stratified
- ☐ Cross validation by feature
- ☐ Random sampling
- Repeat train/test: 10
- Training set size: 66 %
- ☒ Stratified
- ☐ Leave one out
- ☐ Test on train data
- ☐ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.685	0.638	0.637	0.637	0.638	0.268
Random Forest	0.668	0.629	0.627	0.627	0.629	0.249
Naive Bayes	0.677	0.627	0.628	0.630	0.627	0.255

Compare models by: Recall

	Logistic Regression	Random Forest	Naive Bayes
Logistic Regression		0.961	0.998
Random Forest	0.039		0.589
Naive Bayes	0.002	0.411	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Evaluación

AUC

Evalúa la solvencia del algoritmo para distinguir entre el personal que efectivamente abandona la firma y aquel que decide quedarse. Un indicador elevado señala que el sistema prioriza correctamente a los perfiles con mayor probabilidad de rotación, facilitando una detección precisa del talento en situación crítica.

CA (Accuracy)

Representa la proporción de colaboradores clasificados con éxito, contemplando tanto las bajas voluntarias como las permanencias. En este estudio, refleja la frecuencia con la que la herramienta acierta al anticipar la conducta laboral respecto a la continuidad en la nómina.

F1 Score

Integra la Precisión y el Recall en una métrica unificada para ofrecer una visión equilibrada del rendimiento. Es fundamental para este análisis, ya que buscamos identificar las salidas reales sin saturar al área de RRHH con alertas innecesarias, optimizando el balance entre ambos requerimientos.

Precisión

Señala qué porcentaje de las alertas de salida emitidas por el modelo corresponden a renuncias efectivas. Una precisión robusta garantiza que las señales sean fidedignas, evitando el gasto de beneficios o acciones de retención en empleados que no tenían intención de partir.

Recall

Cuantifica la efectividad para capturar a los integrantes que deciden renunciar. Para *People Analytics*, este factor es vital para reducir los falsos negativos, permitiendo que la organización se anticipe y aplique planes de carrera preventivos antes de que el desajuste sea irreversible.

Conclusión: La Regresión Logística fue el modelo con mejor desempeño general, obteniendo los valores más altos de Recall y Precision. Dado que el objetivo principal es minimizar falsos negativos y detectar empleados con riesgo de renuncia, este modelo resulta el más adecuado para el problema analizado.

Prueba

Finalizado el entrenamiento, se avanzó hacia la validación externa del sistema. Para esto, se vinculó el subconjunto de datos reservado (**Test, 20%**) y el algoritmo de **Regresión Logística** al nodo de **Predictions**, permitiendo contrastar la eficacia del modelo.

Los resultados derivados de este procedimiento son los siguientes

- **Matriz de Confusión:** se utilizó para desglosar la solvencia clasificatoria del algoritmo, cuantificando los aciertos y la distribución de errores entre las predicciones y el comportamiento real del personal.

- **Análisis ROC:** se examinó la curva característica para evaluar visualmente la sensibilidad frente a los falsos positivos, determinando con precisión el valor del AUC alcanzado por el modelo seleccionado.

Matriz de confusión

		Predicted		
		0	1	Σ
Actual	0	509	375	884
	1	328	748	1076
Σ		837	1123	1960

Verdaderos Negativos (TN) = 509, Empleados que **no renunciaron** y el modelo predijo correctamente que no renunciarían.

Falsos Positivos (FP) = 375, Empleados que **no renunciaron**, pero el modelo predijo que sí renunciarían.


Falsos Negativos (FN) = 328, Empleados que **sí renunciaron**, pero el modelo predijo que no lo harían.

Verdaderos Positivos (TP) = 748, Empleados que **sí renunciaron** y el modelo los identificó correctamente.

Al examinar la matriz de confusión, se observa una solvencia predictiva aceptable para el negocio. De las **1,076** bajas reales, el algoritmo identificó con éxito **748** instancias, mientras que clasificó correctamente a **509** colaboradores que decidieron quedarse. Aunque el modelo registra **375** falsos positivos y **328** falsos negativos, su exactitud del **63.8%** lo valida como una herramienta de soporte para *People Analytics*.

ROC Analysis

La curva ROC (*Receiver Operating Characteristic*) permite evaluar la capacidad del modelo de Regresión Logística para discriminar entre los empleados que efectivamente renunciarán (Clase 1) y los que permanecerán en la empresa (Clase 0) a lo largo de diferentes umbrales de decisión.




El modelo de **Regresión Logística** demostró ser la mejor opción técnica y estratégica, con un **AUC de 0.685** y una exactitud general del **63.8%**. El análisis de la curva ROC confirma que el modelo posee una capacidad sólida para discriminar y detectar el talento en riesgo de fuga. Al equilibrar de manera óptima la sensibilidad (detección de bajas) con la tasa de falsos positivos, y considerando los costos asociados a los errores de clasificación, este modelo proporciona una herramienta analítica y altamente interpretable para que el departamento de Recursos Humanos implemente planes de retención eficientes y basados en datos.

Interpretación

Nomograma

Esta herramienta permite visualizar de forma directa y gráfica cómo influye cada variable en la probabilidad de que un empleado renuncie, funcionando como un sistema de puntuación acumulativo donde los atributos se ordenan jerárquicamente de mayor a menor impacto.



encuesta_clima_score: Es la variable con mayor peso predictivo en el modelo. Su escala inversa indica que a menor puntuación en la encuesta de clima laboral (valores cercanos a 1.0), mayor es la cantidad de puntos que se suman al riesgo de salida. Los entornos de trabajo desfavorables son el principal motor de la rotación.

anios_rol_actual: Refleja que una prolongada permanencia en el mismo puesto de trabajo (valores altos hacia los 14 años) incrementa la probabilidad de renuncia. Esto puede interpretarse analíticamente como un síntoma de estancamiento profesional.

salario_ars: El modelo muestra un desplazamiento positivo del riesgo a medida que el salario se incrementa.

horas_extra_mes: Un incremento en la carga horaria mensual (valores cercanos a las 39 horas) aporta puntos positivos en el nomograma, asociando el desgaste laboral (*burnout*) directamente con la intención de abandono.

Comparación con las hipótesis del EDA

H1 – Salario relativo a la región

No se confirma.

No se confirma la linealidad, pero se descubre un patrón crítico. El análisis de la distribución revela que las tasas de renuncia se emparejan en los salarios bajos, pero la brecha a favor de las renuncias se ensancha notablemente en los rangos salariales medios y altos. El salario no es un factor aislado, sino un factor que potencia el riesgo en los niveles de mayor ingresos. Por su parte, la distribución del problema es completamente homogénea en todas las provincias

H2 – Flexibilidad y distancia

No se confirma.

Ni la modalidad de trabajo ni la distancia a la oficina mostraron capacidad predictiva relevante sobre la renuncia.

H3 – Burnout por sobretiempo y clima bajo

Se confirma fuertemente.

Los empleados con clima laboral bajo y alta carga de horas extra alcanzaron una tasa de renuncia del 77,1%, muy superior al promedio general. Fue el hallazgo más importante del análisis.

H4 – Estancamiento profesional

Se confirma parcialmente.

Los empleados que permanecen varios años en el mismo rol presentan una tasa de renuncia significativamente superior a quienes tuvieron movilidad interna.

H5 – Presión por desempeño

No se confirma.

Las evaluaciones de desempeño no mostraron relación significativa con la probabilidad de renuncia.

Hallazgo sorprendente

Uno de los resultados más contraintuitivos fue que **los salarios bajos prácticamente no tuvieron relación con la renuncia**. En la mayoría de las organizaciones se asume que una compensación inferior al mercado aumenta el riesgo de fuga de talento; sin embargo, en este dataset los niveles salariales más bajos presentan tasas de rotación y permanencia equilibradas. El verdadero patrón de riesgo se evidencia a partir de la mediana y hacia los rangos salariales medios y altos (perfiles senior o especializados), donde la brecha a favor de las renuncias se ensancha de forma sostenida. En este dataset los empleados parecen responder mucho más a factores relacionados con bienestar laboral, clima organizacional y oportunidades de crecimiento interno.

Recomendaciones

Recomendación 1: Programa de prevención de burnout

Implementar alertas tempranas para empleados con:

- muchas horas extra,
- bajo puntaje de clima laboral,
- aumento sostenido de carga de trabajo.

Dado que este grupo presenta la mayor tasa de renuncia, las acciones preventivas tendrían un impacto directo en la retención.

Recomendación 2: Planes de movilidad interna

Diseñar programas de rotación, promociones y desarrollo profesional para empleados con varios años en el mismo puesto.

El análisis muestra que el estancamiento profesional es uno de los principales factores asociados a la salida de empleados.

Recomendación 3: Encuestas de clima más frecuentes

Pasar de encuestas anuales a encuestas trimestrales o mensuales para detectar rápidamente caídas en la satisfacción laboral.

Conclusión Final

Tras el estudio predictivo efectuado para GrupoSer S.A., podemos concluir que la gestión de la rotación no depende de las nociones convencionales, dimensiones estándar como la remuneración, el trayecto a la oficina o el desempeño. El núcleo de la problemática se concentra en dos ejes determinantes: el desgaste laboral y el estancamiento profesional.