



Ejercicio: Análisis Predictivo con el Titanic



Paso 2

¿Se cumple la regla "mujeres y niños primero"?

Sí, y de forma muy contundente. El histograma muestra que de las mujeres, aproximadamente 233 sobrevivieron contra solo ~80 que no lo hicieron (~74% de supervivencia femenina). En los hombres la situación es inversa: ~468 fallecieron y solo ~109 sobrevivieron (~81% de mortalidad masculina). La barra roja femenina supera ampliamente a la azul, mientras que en los hombres ocurre exactamente lo contrario. La regla se confirma visualmente de forma clara.




¿Los pasajeros que pagaron una tarifa más alta tuvieron más chances de sobrevivir?

El Scatter Plot de *Age vs Fare* fue configurado con "Same color" para todos los puntos, por lo que no permite distinguir visualmente sobrevivientes de no sobrevivientes. Para responder esta pregunta correctamente habría que haber seteado el atributo Color en *Survived*. Sin esa configuración, el gráfico solo permite observar la distribución general: la gran mayoría de pasajeros pagó tarifas bajas (entre 0 y 50), con muy pocos outliers por encima de 300-500. En base al conocimiento del dataset, sí existe una tendencia: los pasajeros con tarifas más altas (1ra clase) tendieron a sobrevivir más por tener acceso prioritario a los botes salvavidas.

¿Los pasajeros que pagaron una tarifa más alta tuvieron más chances de sobrevivir?

Sí, se puede observar una tendencia clara en el gráfico. Los puntos **rojos (Survived = 1)** aparecen con mayor frecuencia en valores altos de *Fare* (por encima de 100, 200 e incluso 500), mientras que los puntos **azules (Survived = 0)** se concentran masivamente en la franja inferior del eje Y, cerca de 0-50.

En los outliers más extremos (tarifas de 500+) se ven predominantemente puntos rojos, lo que refuerza la idea de que pagar más es decir, viajar en 1ra clase estuvo asociado a una mayor probabilidad de sobrevivir, probablemente por el acceso prioritario a los botes salvavidas.




¿Existen valores atípicos (outliers) en la edad de los sobrevivientes?

Sí. El Box Plot agrupado por *Survived* muestra:

- Grupo 1 (sobrevivió): media de edad = 28.34 años $\pm$ 14.93
- Grupo 0 (no sobrevivió): media de edad = 30.63 años $\pm$ 14.16

Ambos grupos presentan outliers en edades superiores a 60-70 años, con bigotes que se extienden hasta aproximadamente 80 años. La diferencia de medias entre grupos es estadísticamente significativa (Student's $t = 2.049$, $p = 0.041$), lo que confirma que la edad tuvo un efecto real aunque moderado: los sobrevivientes eran en promedio algo más jóvenes.



Paso 5 – Evaluación del Modelo

¿Cuál es el valor de CA obtenido?

se muestran dos métricas:

- Predictions (set de test): CA = 0.809
- Test and Score (cross-validation 5 folds): CA = 0.765

El valor más robusto y representativo es el de cross-validation: 0.765, ya que promedia el rendimiento sobre múltiples particiones de los datos y reduce el riesgo de sobreajuste.

Predictions

Show probabilities for: Classes in data ☒ Show classification errors Restore Original Order

	Tree	error	Survived	Name	Ticket	Cabin	PassengerId	
1	0.95 : 0.05 → 0	0.955	1	Barah, Mr. H...	2663	?	763	3
2	1.00 : 0.00 → 0	1.000	1	Harper, Mr. H...	PC 17572	D33	646	1
3	0.00 : 1.00 → 1	0.000	1	Hamalainen, ...	250649	?	756	2

☒ Show performance scores Target class: (Average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.761	0.809	0.809	0.809	0.809	0.579

? | 178 | 178 | 1x178

Test and Score

☒ Cross validation
 Number of folds: 5
☒ Stratified
☐ Cross validation by feature
☐ Random sampling
 Repeat train/test: 10
 Training set size: 66 %
☒ Stratified
☐ Leave one out
☐ Test on train data
☐ Test on test data

Evaluation results for target: (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.744	0.765	0.763	0.762	0.765	0.501

Compare models by: Area under ROC curve ☐ Negligible diff.: 0.1

	Tree
Tree	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

? | 714 | 714 | 1x714

¿Cómo se interpreta?

Significa que el modelo predijo correctamente si un pasajero sobrevivió o no en el 76.5% de los casos evaluados mediante validación cruzada. En el set de test puntual alcanzó el 80.9% de predicciones correctas.

¿Un CA de 0.765-0.809 es "bueno"?

Es un resultado razonable para un árbol de decisión simple, pero depende del contexto. Hay que considerar que el dataset está algo desbalanceado (más fallecidos que sobrevivientes), por lo que el CA solo no es suficiente para evaluar el modelo.

Paso 7 – Predicciones

pasajero mal predicho:

la fila 1: Baran, Mr. H... con probabilidad predicha de 0.95:0.05 $\rightarrow$ clase 0 (no sobrevivió), pero *Survived* = 1 (sí sobrevivió). Este es un Falso Negativo: el modelo estaba muy seguro (95%) de que no iba a sobrevivir, pero sobrevivió.

¿Qué pudo confundir al árbol?

El árbol lo clasificó como "no sobreviviente" porque es un hombre (*Mr.*), y el género masculino es la variable con mayor peso en el modelo. La regla general "*hombre $\rightarrow$ no sobrevive*" lo perjudicó, ignorando otros factores particulares de ese pasajero (clase, edad, si viajaba con familia) que en la realidad sí influyeron en su supervivencia.